

Bitácora de Proyecto Technical AI Safety

Ideas pensadas:

Contribuir a Petri o investigar su funcionamiento interno

Petri es el framework de auditoría de Anthropic construido sobre Inspect AI. Tiene dos modos de uso posibles como proyecto BlueDot:

Opción A — Contribución de código (issues/PRs): Petri es relativamente nuevo y tiene menos contributors que TransformerLens. Las contribuciones más útiles para un engineer son: mejor logging y reproducibilidad de experimentos, abstracciones para reutilizar configuraciones de auditoría entre proyectos, mejoras en la interfaz del judge (actualmente requiere bastante boilerplate para definir rubrics custom), y documentación de patrones de uso para researchers sin background de software. El impacto es multiplicador: una mejora en Petri facilita todos los proyectos que lo usan (#11, #13, y cualquier auditoría futura).

Opción B — Investigar Petri como objeto de estudio: En lugar de mejorarlo, usarlo para entender sus propias limitaciones. Preguntas concretas: ¿Qué tan sensible es el judge a cambios menores en el wording de la rubric? ¿El auditor autónomo de Petri introduce sesgos sistemáticos según el modelo target? ¿La evaluación multi-turn captura comportamientos que la evaluación single-turn no? Esto conecta con los proyectos #5 y #6 del documento (anchoring en monitors, inconsistencia de verdicts bajo temperatura) pero aplicado al propio Petri en lugar de monitores externos.

Conexión con AI Safety: Si Petri se usa para auditorías de pre-deployment (como lo usó Anthropic para Claude Sonnet 4.5), sus puntos ciegos son puntos ciegos de seguridad. Entender dónde falla el framework de auditoría es tan importante como los resultados que produce.

Resumen e Idea Seleccionada

Actualizame seguido! Un párrafo que describa:

- Qué paper, idea, o experimento estás desarrollando
- Qué intentaste resolver
- Cómo se conecta con las agendas de AI Safety

Does Abliteration Remove Safety Uniformly Across Languages in Small Language Models?

Research Field: Multilingual LLM Safety / Mechanistic Interpretability

Research Question: Cuando se abliteran las direcciones de refusal de un SLM (Small Language Model) usando pares de contraste en inglés, ¿se elimina la safety de manera uniforme en otros idiomas, o existen idiomas donde la safety sobrevive parcialmente, sugiriendo geometrías de refusal independientes? ¿Es la vulnerabilidad más severa en

modelos pequeños y democráticamente accesibles que en modelos más grandes?

Approach: Partiendo de la familia Gemma 4 (modelos que van desde versiones que corren en celulares hasta la variante que corre en una 4090), se toma el modelo ya abliterado disponible públicamente (TrevorS/gemma-4-abliteration, que computa la dirección de refusal desde pares en inglés) y se evalúa su compliance rate en 5-6 idiomas (inglés, español, chino, árabe, hindi, portugués) usando ~50 prompts dañinos traducidos. Se comparan las tasas de compliance post-abliteration entre idiomas. Adicionalmente, se replican las visualizaciones PCA y los Silhouette Scores del paper de Wang et al. (2025) — "Refusal Direction is Universal Across Safety-Aligned Languages" — para Gemma 4, verificando si la separación entre representaciones dañinas y benignas es peor en modelos pequeños que en los modelos más grandes estudiados en ese paper (LLaMA-8B, Qwen-7B, Gemma-2-9B). La motivación surge de una conversación con mi mentor Guido, quien señaló que la combinación de SLMs + multilingüidad está sub-investigada y recomendó el paper de Wang et al. como referencia directa. Ese paper demuestra que las direcciones de refusal son paralelas entre idiomas (la abliteration en inglés colapsa la safety en todos los idiomas), pero también muestra que la separación de clusters harmful/harmless se degrada en idiomas no-ingleses — los puntos de jailbreak caen en la zona intermedia donde los clusters se solapan. Mi trabajo extiende estos hallazgos a SLMs, donde la hipótesis es que la degradación de separación será aún más pronunciada, haciendo la abliteration trivialmente efectiva.

Hypotheses: (1) La abliteration basada en inglés elimina la safety en todos los idiomas evaluados, replicando la universalidad encontrada por Wang et al. en modelos más grandes. (2) Los Silhouette Scores de Gemma 4 serán menores que los reportados para LLaMA/Qwen/Gemma-2, indicando peor separación harmful/harmless de base. (3) Idiomas de bajos recursos (árabe, hindi) mostrarán compliance rates post-abliteration más altos que idiomas de altos recursos (español, portugués).

Metrics: Compliance rate por idioma pre y post abliteration. Silhouette Scores de clusters harmful/harmless por idioma. Cosine similarity entre direcciones de refusal cross-lingüísticas. Evaluación de outputs via LLM-as-judge (Claude o GPT-4 como evaluador, siguiendo la metodología WildGuard del paper de referencia).

Impact Chain: La proliferación de SLMs abliterados a las 48 horas de su lanzamiento público representa un riesgo concreto de safety: modelos que cualquier persona puede correr localmente sin censura, en más de 140 idiomas. Si la abliteration en inglés efectivamente colapsa la safety multilingüe en estos modelos, esto tiene implicancias directas para el diseño de defensas, no alcanza con mejorar la safety en inglés, y la separación de representaciones harmful/harmless en idiomas no-ingleses necesita ser un objetivo explícito de entrenamiento. Este trabajo aporta evidencia empírica sobre si los modelos más accesibles son también los más vulnerables, conectando directamente con la agenda de democratización segura de modelos abiertos.

Bitácora

Agrega tu último log primero:

- Qué hice:
- Qué esperaba vs. qué sucedió:
- Cómo cambia lo que pienso:
- Sigüientes pasos:

8 Apr 2026

- Analice hacer un paper con Gemma 4, investigue sobre el tema

9 Apr 2026

- Con la info de Gemma 4 pensé como sus características se podrían relacionar con las ideas propuestas en el docs y relacionarlo donde podía combinarlos.

10 Apr 2026

- Consulte a facilitadores del curso sobre la idea propuesta

11 Apr 2026

- Determine la idea y escribi su resumen

8 Apr 2026